Llenguatges de Marques i Sistemes de Gestió d'Informació

UD 3.1 XPath





Índex

		XPATH: XML PATH LANGUAGE		
	1.1	Arbre o	del document	2
	1.2	Tipus	de nodes	4
	1.3	Sintax	i de les expressions XPath	5
	1.4	Sintax	i abreviada	6
		1.4.1	Eix (en anglès, axis)	6
		1.4.2	Predicat (en anglés, predicate)	9
		1.4.3	Selecció de nodes (en anglés, node test)	12
		1.4.4	Passos de cerca consecutius	15
		1.4.5	Expressions niuades	17
	1.5	Referè	ncies	19

1 3.1. XPATH: XML PATH LANGUAGE

XPath és un llenguatge que permet seleccionar nodes d'un document XML i calcular valors a partir del seu contingut. Existeixen diverses versions d'XPath aprovades pel W3C, encara que la més utilitzada continua sent la versió 1:

- novembre de 1999: XML Path Language 1.0
- gener de 2007: XML Path Language 2.0
- desembre de 2010: XML Path Language 2.0 (2a edició)
- abril de 2014: XML Path Language 3.0
- març de 2017: XPath 3.1

1.1 Arbre del document

XPath considera un document XML com un arbre de nodes. En Informàtica, un arbre és una estructura de dades que equival a un arbre matemàtic. En Matemàtiques, un arbre és un cas particular de graf. Els següents termes definits en teoria de grafs s'utilitzen també en Informàtica i en XPath:

• Un **graf** és un conjunt d'objectes anomenats nodes o vèrtexs units per enllaços anomenats arcs o arestes. Un graf dirigit és un graf en el qual els arcs tenen direcció.



• Quan dos nodes estan units per un arc amb direcció, el **node pare** és el node del qual parteix l'arc i el **node fill** és el node al qual arriba l'arc.

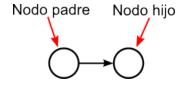
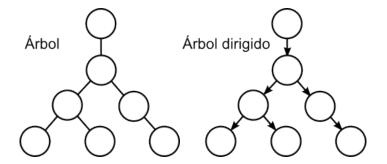


Figura 1: Nodes pare i fill

• Un **arbre** és un graf en el qual qualsevol parella de vèrtexs està connectada per un únic camí (és a dir, que no hi ha cicles). Un arbre dirigit és un arbre en el qual les arestes tenen direcció i tots els nodes menys un tenen un únic pare.



• El **node arrel** d'un arbre dirigit és l'únic node sense pare. Els nodes germans són els nodes que tenen el mateix pare.

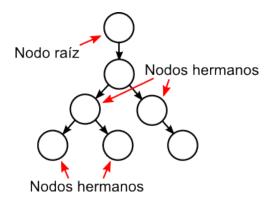
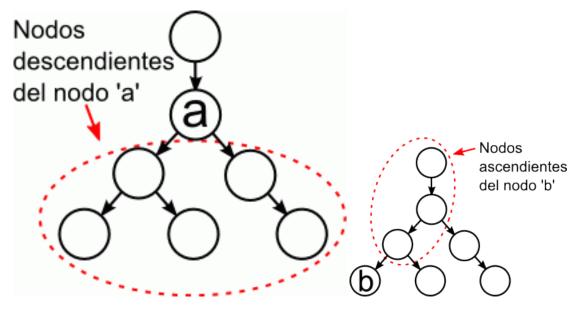


Figura 2: Node arrel

• Els **nodes descendents** d'un node són tots els nodes als quals s'arriba des del node: els fills, els fills dels fills, etc. Els **nodes ascendents** d'un node són tots els nodes dels quals un node és descendent: el pare, el pare del pare, etc.



1.2 Tipus de nodes

Un document XML es pot representar com un arbre dirigit, considerant per exemple els elements com a nodes i que un element és pare dels elements que conté. Però en XPath no només els elements són nodes, en realitat hi ha set tipus de nodes:

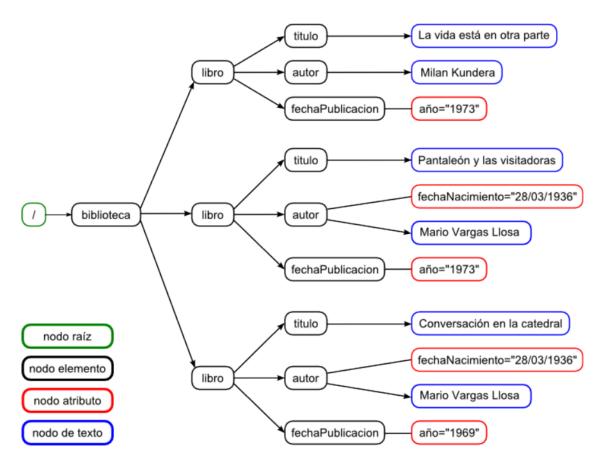
- Arrel
- Element
- Atribut
- Text
- Comentari
- Instrucció de processament
- Espai de noms

La declaració DOCTYPE no es considera com a node.

Per exemple, el següent document XML:

```
<?xml version="1.0" encoding="UTF-8"?>
<br/>
<br/>
diblioteca>
 libro>
    <titulo>La vida está en otra parte</titulo>
    <autor>Milan Kundera</autor>
    <fechaPublicacion año="1973"/>
 </libro>
 libro>
    <titulo>Pantaleón y las visitadoras</titulo>
    <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa/autor>
    <fechaPublicacion año="1973"/>
 </libro>
 libro>
    <titulo>Conversación en la catedral</titulo>
    <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
    <fechaPublicacion año="1969"/>
 </libro>
</biblioteca>
```

es pot representar amb el següent arbre:



Els nodes atributs i de text no són com els nodes element. Per exemple, els nodes atributs i de text no poden tenir descendents. En realitat el node atribut ni tan sols es considera fill, sinó com una etiqueta adossada a l'element. El text contingut per una etiqueta sí que es considera fill de l'element, encara que les expressions XPath solen treballar amb nodes element i per referir-se als atributs o text s'utilitzen notacions especials.

1.3 Sintaxi de les expressions XPath

Una **expressió XPath** és una cadena de text que representa un recorregut en l'arbre del document. Les expressions més simples s'assemblen a les rutes dels arxius en l'explorador de Windows o en la shell de GNU/Linux.

Avaluar una expressió XPath és cercar si hi ha nodes al document que s'ajusten al recorregut definit a l'expressió. Els resultats de l'avaluació són tots els nodes que s'ajusten a l'expressió. Per a avaluar una expressió XPath, el document ha d'estar ben format.

Les expressions XPath es poden escriure de dues maneres diferents:

• sintaxi abreviada: més compacta i fàcil de llegir, que s'explica en aquesta lliçó

• sintaxi completa: més llarga però amb més opcions disponibles

Les expressions XPath es poden dividir en passos de cerca. Cada pas de cerca es pot dividir en tres parts:

- eix: selecciona nodes element o atribut basant-se en els noms.
- predicat: restringeix la selecció de l'eix a què els nodes compleixin certes condicions.
- **selecció de nodes**: dels nodes seleccionats per l'eix i el predicat, selecciona els elements, el text que contenen o tots dos.

1.4 Sintaxi abreviada

Exemples d'expressions XPath de sintaxi abreviada i el resultat de la seva avaluació en el document d'exemple anterior:

```
/biblioteca/libro/autor
<autor>Milan Kundera</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

Nota: En XPath 1.0 no es pot seleccionar únicament el valor de l'atribut, sinó que s'obtenen respostes del tipus nomDeAtribut=ValorDeAtribut.

1.4.1 Eix (en anglès, axis)

L'eix ens permet seleccionar un subconjunt de nodes del document i correspon a recorreguts en l'arbre del document. Els nodes element es marquen amb el nom de l'element. Els nodes atribut es marquen amb @ i el nom de l'atribut.

• /: si està al principi de l'expressió, indica el node arrel; si no, indica "fill". Ha d'anar seguit del nom d'un element.

```
Expressió: /biblioteca/libro/autor Resultat:
```

```
<autor>Milan Kundera
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

Expressió: /autor

Resultat: No retorna res perquè <autor> no és fill del node arrel.

Expressió: /biblioteca/autor

Resultat: No retorna res perquè <autor> no és fill de <biblioteca>.

Expressió: /biblioteca/libro/autor/@fechaNacimiento

Resultat:

fechaNacimiento="28/03/1936" fechaNacimiento="28/03/1936"

Expressió: /biblioteca/libro/@fechaNacimiento

Resultat: No retorna res perquè bro> no té l'atribut fechaNacimiento.

Nota: En XPath 1.0 no es pot seleccionar únicament el valor de l'atribut, sinó que s'obtenen respostes del tipus nomDeAtribut=ValorDeAtribut.

• //: indica "descendent" (fills, fills dels fills, etc.).

Expressió: /biblioteca//autor

Resultat:

```
<autor>Milan Kundera
<autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

Expressió: //autor

Resultat:

```
<autor>Milan Kundera</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

Expressió: //autor//libro

Resultat: No retorna res perquè < libro > no és descendent de < autor >.

Expressió: //@año

Resultat:

```
año="1973"
año="1973"
año="1969"
```

• /..: indica l'element pare.

```
Expressió: /biblioteca/libro/autor/@fechaNacimiento/...
Resultat:
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
Expressió: //@fechaNacimiento/../..
Resultat:
libro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
tibro>
  <titulo>Conversación en la catedral</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1969"/>
</libro>
  Nota: En aquests exemples es seleccionen únicament els nodes que tenen l'atribut fechaNa-
  cimiento.
```

• |: permet indicar diversos recorreguts.

```
Expressio: //autor|//titulo
Resultat:

<titulo>La vida está en otra parte</titulo>
<autor>Milan Kundera</autor>
<titulo>Pantaleón y las visitadoras</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<titulo>Conversación en la catedral</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
Expressio: //autor|//titulo|//@año
Resultat:
<titulo>La vida está en otra parte</titulo>
```

año="1973"

<autor>Milan Kundera</autor>

```
<titulo>Pantaleón y las visitadoras</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
año="1973"
<titulo>Conversación en la catedral</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
año="1969"
```

1.4.2 Predicat (en anglés, predicate)

El predicat s'escriu entre claudàtors, a continuació de l'eix. Si l'eix ha seleccionat uns nodes, el predicat permet restringir aquesta selecció als que complisquen determinades condicions.

• [@atribut]: selecciona els elements que tenen l'atribut.

```
Expressió: //autor[@fechaNacimiento]
Resultat:
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

• [número]: si hi ha diversos resultats, selecciona un d'ells per número d'ordre; last() selecciona l'últim d'ells.

• [condició]: selecciona els nodes que compleixen la condició.

Els predicats permeten definir condicions sobre els valors dels atributs. En les condicions es poden utilitzar els operadors següents:

- Operadors lògics: and, or, not()
- Operadors aritmètics: +, -, *, div, mod
- Operadors de comparació: =, !=, <, >, <=, >=

Les comparacions es poden fer entre valors de nodes i atributs o amb cadenes de text o numèriques. En el cas de les cadenes de text, han d'estar envoltades per cometes simples o dobles. En el cas de les cadenes numèriques, les cometes són optatives.

• La condició pot utilitzar el valor d'un atribut (utilitzant @) o el text que conté l'element.

En els exemples següents s'obtenen, respectivament, els elements < fechaPublicacion> el valor de l'atribut año dels quals és posterior/major a 1970 i els elements < libro> el subelement < autor> del qual té com a contingut "Mario Vargas Llosa":

```
<titulo>Conversación en la catedral</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<fechaPublicacion año="1969"/>
</libro>
```

• Per fer referència al propi valor de l'element seleccionat s'utilitza el punt (.).

```
Expressió: //@año[.>1970]
Resultat:
año="1973"
año="1973"

Expressió: //autor[.="Mario Vargas Llosa"]
Resultat:
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor></autor</pre>
```

• Es poden escriure diversos predicats seguits, cadascun dels quals restringeix els resultats de l'anterior, com si estigueren encadenats per l'operació lògica and.

En l'exemple següent es seleccionen els llibres escrits per Mario Vargas Llosa i publicats en 1973:

Expressió: //libro[autor="Mario Vargas Llosa"][fechaPublicacion/@año="1973"]
Resultat:

```
libro>
    <titulo>Pantaleón y las visitadoras</titulo>
    <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
    <fechaPublicacion año="1973"/>
</libro>
```

• Un predicat pot contenir condicions compostes.

En els exemples següents es seleccionen, respectivament, els llibres escrits per Mario Vargas Llosa i publicats en 1973 (primer exemple) i els llibres escrits per Mario Vargas Llosa o publicats en 1973 (segon exemple):

Expressió://libro[autor="Mario Vargas Llosa" and fechaPublicacion/@año="1973"] Resultat:

```
<libro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
```

```
Expressió: //libro[autor="Mario Vargas Llosa" or fechaPublicacion/@año="1973"] Resultat:
```

• També es pot buscar part del contingut d'un node de text mitjançant la funció contains (nom_element, "text_a_buscar"):

```
Expressio //libro[contains(titulo, "Pantaleón")]
Resultat:
```

```
<libro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
```

1.4.3 Selecció de nodes (en anglés, node test)

La selecció de nodes s'escriu a continuació de l'eix i el predicat. Si l'eix i el predicat han seleccionat uns nodes, la selecció de nodes indica amb quina part d'aquests nodes ens quedem.

- /node(): selecciona tots els fills (elements o text) del node.
- //node(): selecciona tots els descendents (elements o text) del node.

```
Expressio: //libro/node()
Resultat:

<titulo>La vida está en otra parte</titulo>
<autor>Milan Kundera</autor>
```

```
<fechaPublicacion año="1973"/>
<titulo>Pantaleón y las visitadoras</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<fechaPublicacion año="1973"/>
<titulo>Conversación en la catedral</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<fechaPublicacion año="1969"/>

Expressió: //autor/node()

Resultat:

Milan Kundera
Mario Vargas Llosa
Mario Vargas Llosa

- /text(): selecciona únicament el text contingut en el node.
```

• //text(): selecciona únicament el text contingut en el node i tots els seus descendents.

Expressió: //autor/text()

Resultat:

Milan Kundera Mario Vargas Llosa Mario Vargas Llosa

Expressió: //libro/text()

Resultat: No retorna res perquè <llibre> no conté text.

Expressio: //libro//text()

Resultat:

La vida està en un altre lloc Milan Kundera Pantaleó i les visitadores Mario Vargas Llosa Conversació en la catedral Mario Vargas Llosa

- /*: selecciona tots els fills (només elements) del node.
- //*: selecciona tots els descendents (només elements) del node.

```
Expressió: /biblioteca/*
Resultat:
libro>
  <titulo>La vida está en otra parte</titulo>
  <autor>Milan Kundera</autor>
  <fechaPublicacion año="1973"/>
</libro>
tibro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
libro>
  <titulo>Conversación en la catedral</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1969"/>
</libro>
Expressió: //autor/*
Resultat: No retorna res perquè <autor> només conté text.
Expressió: /biblioteca//*
Resultat:
libro>
  <titulo>La vida está en otra parte</titulo>
  <autor>Milan Kundera
  <fechaPublicacion año="1973"/>
</libro>
<titulo>La vida está en otra parte</titulo>
<autor>Milan Kundera</autor>
<fechaPublicacion año="1973"/>
libro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
<titulo>Pantaleón y las visitadoras</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<fechaPublicacion año="1973"/>
libro>
  <titulo>Conversación en la catedral</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

```
<fechaPublicacion año="1969"/>
</libro>
<titulo>Conversación en la catedral</titulo>
<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
<fechaPublicacion año="1969"/>
```

- /@*: selecciona tots els atributs del node.
- //@*: selecciona tots els atributs dels descendents del node.

```
Expressió: //@*
```

Resultat:

```
año="1973"
fechaNacimiento="28/03/1936"
año="1973"
fechaNacimiento="28/03/1936"
año="1969"
```

Expressió: //libro/@*

Resultat: No retorna res perquè <llibre> no té atributs.

Expressió: //autor/@*

Resultat:

`fechaNacimiento="28/03/1936"`

Nota: En XPath 1.0 no es pot seleccionar únicament el valor de l'atribut, sinó que s'obtenen respostes del tipus nomAtribut=valorAtribut.

1.4.4 Passos de cerca consecutius

Una expressió XPath pot contindre diversos passos de cerca consecutius. Cada un inclourà el seu eix (i, si és el cas, el seu predicat) i l'últim pas de cerca inclourà, si és el cas, una selecció de nodes. Cada pas de cerca treballa a partir dels nodes seleccionats pel pas de cerca anterior.

En l'exemple següent s'obtenen els títols dels llibres publicats després de 1970, mitjançant dos passos de cerca: - En el primer pas (//fechaPublicacion[@año>1970]) se seleccionen els elements <fechaPublicacion> que tinguen l'atribut año superior a 1970. - En el segon pas (/../titulo), se seleccionen primer els elements pare (/..) dels <fechaPublicacion> seleccionats en el primer pas de cerca (és a dir, elements <libro>) i a continuació els seus subelements <titulo>.

[`]fechaNacimiento="28/03/1936"`

```
Expressio: //fechaPublicacion[@año>1970]/../titulo
Resultat:
<titulo>La vida está en otra parte</titulo>
<titulo>Pantaleón y las visitadoras</titulo>
```

Un determinat resultat es pot obtindre mitjançant un únic pas de cerca o mitjançant diversos passos.

- En els exemples següents s'obtenen els llibres escrits per Mario Vargas Llosa de dues formes diferents:
 - mitjançant un únic pas de cerca. Se seleccionen els elements libro> el subelement dels quals <autor> té com a contingut la cadena "Mario Vargas Llosa".

```
Expressió: //libro[autor="Mario Vargas Llosa"]
Resultat:
```

```
<libro>
  <titulo>Pantaleón y las visitadoras</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1973"/>
</libro>
  <titulo>Conversación en la catedral</titulo>
  <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
  <fechaPublicacion año="1969"/>
</libro>
```

• mitjançant dos passos de cerca. En el primer pas se seleccionen els elements <autor> el contingut dels quals és la cadena "Mario Vargas Llosa". En el segon pas de cerca se seleccionen els elements pare (és a dir, els elements libro>).

```
Expressio: //autor[.="Mario Vargas Llosa"]/..
Resultat:
```

```
libro>
    <titulo>Pantaleón y las visitadoras</titulo>
    <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
    <fechaPublicacion año="1973"/>
</libro>
    libro>
        <titulo>Conversación en la catedral</titulo>
        <autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
        <fechaPublicacion año="1969"/>
</libro>
```

• En els exemples següents s'obté l'autor que ha publicat llibres en 1969 de diverses formes diferents:

```
Expressio: //@año[.=1969]/../../autor
Resultat:

<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
Expressio: //libro[fechaPublicacion/@año=1969]/autor
Resultat:

<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
Expressio: //fechaPublicacion[@año=1969]/../autor
Resultat:

<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
Expressio: //autor[../fechaPublicacion/@año=1969]
Resultat:

<autor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
cautor fechaNacimiento="28/03/1936">Mario Vargas Llosa</autor>
```

1.4.5 Expressions niuades

Les expressions XPath poden niuar-se, la qual cosa permet definir expressions més complexes. Per exemple, en el document utilitzat anteriorment, un exemple d'expressió niada seria, per exemple, obtindre els títols dels llibres publicats el mateix any que la novel·la "La vida está en otra parte". Aquesta informació no està directament emmagatzemada en el document, però es pot obtindre la resposta en dos passos: - obtindre primer l'any en què es va publicar la novel·la "La vida està en un altre lloc":

Expressió: //libro[titulo="La vida está en otra parte"]/fechaPublicacion/@año Resultat:

```
año="1973"
```

• i obtindre després els títols dels llibres publicats en 1973:

Expressió: //libro[fechaPublicacion/@año=1973]/titulo **Resultat**:

```
<titulo>La vida está en otra parte</titulo>
<titulo>Pantaleón y las visitadoras</titulo>
```

Aquestes dues expressions es poden unir en una única expressió, substituint en la segona expressió el valor 1973 per la primera expressió:

Expressió: //libro[fechaPublicacion/@año=//libro[titulo="La vida está en otra parte"]/fechaPublicacion/@año]/titulo

Resultat:

```
<titulo>La vida está en otra parte</titulo>
<titulo>Pantaleón y las visitadoras</titulo>
```

Com que cada una de les expressions es pot escriure de diverses maneres, en realitat hi ha moltes formes de trobar la resposta. Per exemple, en la solució següent els predicats es troben al final de l'eix en cada subexpressió:

Expressió: //titulo[../fechaPublicacion/@año=//@año[../../titulo="La vida está en otra parte"]]

Resultat:

```
<titulo>La vida está en otra parte</titulo>
<titulo>Pantaleón y las visitadoras</titulo>
```

Un altre exemple d'expressió niuada seria obtindre els títols dels llibres del mateix autor que la novel·la "Pantaleón y las visitadoras". Com en l'exemple anterior, la resposta pot obtindre's en dos passos: - obtindre primer l'autor de la novel·la "Pantaleón y las visitadoras":

```
Expressió: //libro[titulo="Pantaleón y las visitadoras"]/autor/text()
Resultat:
```

Mario Vargas Llosa

• i obtindre després els títols dels llibres escrits per Mario Vargas Llosa:

Expressió: //libro[autor="Mario Vargas Llosa"]/titulo
Resultat:

```
<titulo>Pantaleón y las visitadoras</titulo><titulo>Conversación en la catedral</titulo>
```

Aquestes dues expressions es poden unir en una única expressió, substituint en la segona expressió el valor "Mario Vargas Llosa" per la primera expressió:

```
Expressió: //libro[autor=//libro[titulo="Pantaleón y las visitado-ras"]/autor/text()]/titulo
```

Resultat:

```
<titulo>Pantaleón y las visitadoras</titulo>
<titulo>Conversación en la catedral</titulo>
```

Un detall important és que no cal escriure la primera expressió entre cometes. Fins i tot es pot ometre la selecció de nodes /text() de la segona expressió i escriure l'expressió XPath així:

1.5 Referències

Aquestes notes estan extretes de la pàgina de Bartolomé Sintes Marco: enllaç a la pàgina

<titulo>Conversación en la catedral</titulo>